Clasificación usando Árboles y Reglas de Decisión

Jorge Gallego

Facultad de Economía, Universidad del Rosario

Junio 22 de 2017

Árboles de Decisión

- Los árboles de decisión de aprendizaje sirven para hacer clasificaciones
- Utilizan una estructura de árbol para modelar la relación entre características y *outcomes* potenciales
- Arrancamos con un tronco que incluye todos los casos
- Y vamos creando ramificaciones en función de las características de interés
- Hasta que los objetos terminan clasificados en una clase pronosticada final

Ejemplo Árbol de Decisión

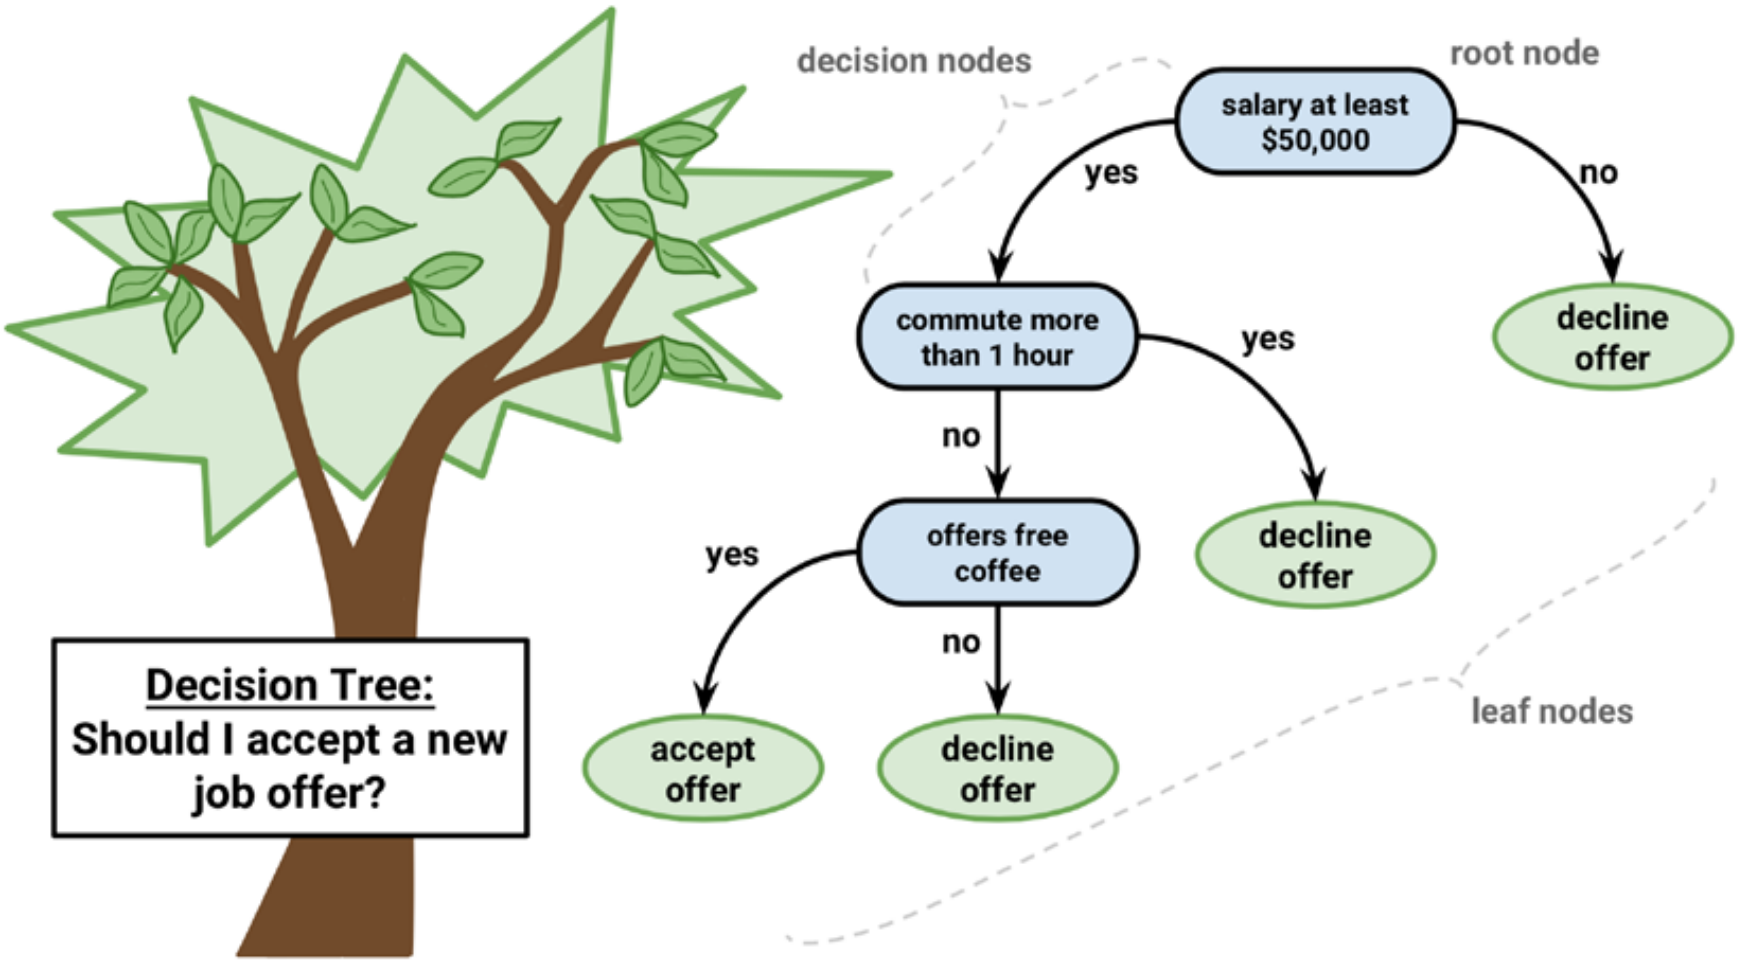

Árboles de Decisión

- En el ejemplo los objetos a clasificar son ofertas de trabajo
- La predicción es la clase a la qué pertenece cada oferta
- Donde los niveles son si se acepta o no el trabajo
- La primera rama la define el salario. La segunda el tiempo de desplazamiento. La tercera si ofrece café
- El árbol tiene nodo raíz, nodos de decisión y nodos de hojas

Árboles de Decisión

- Una ventaja de los árboles es que el formato no es exclusivo del método
- También se puede presentar de una forma amigable
- Lo cual es útil cuando se tiene que justificar una decisión
- Por ejemplo, cuando se le niega un crédito a alguien
- En términos legales o corporativos esto es muy útil

Árboles de Decisión

De esta forma, algunas de las aplicaciones incluyen:

1. Modelos de *score* crediticio. Los criterios para rechazar a alguien deben ser documentados y libres de sesgo

2. Estudios de marketing de comportamiento del consumidor para medir satisfacción.

3. Diagnóstico de condiciones médicas basadas en tomas de laboratorio, síntomas o tasa de progresión de una enfermedad

Existen muchas otras aplicaciones, este es uno de los métodos más populares

Árboles de Decisión

- Los árboles de decisión se basan en el principio de **partición**
- También se le llama *divide y triunfarás*
- Se dividen los datos en subconjuntos, y estos en subconjuntos más pequeños
- Así hasta que el algoritmo determina que los datos en cada subconjunto son suficientemente homogéneos

Árboles de Decisión

- Veamos el proceso con un ejemplo: clasificación de películas
- Ud. trabaja para un estudio de Hollywood y debe decidir si el estudio debe producir un guíon
- Tiene un montón de guíones sobre los cuales decidir pero no tiene tiempo para leerlos
- Decide desarrollar un árbol de decisión para predecir
- Debe predecir si cada guión cae en una de tres categorías: éxito para la crítica, éxito para el público o fracaso de taquilla

Árboles de Decisión

- Para construir al árbol ud. examina los factores que llevaron al éxito o fracaso las últimas 30 películas
- Descubre la relación entre el presupuesto de la película, el número de actores estrella y el éxito
- De hecho ud. encuentra el siguiente *scatterplot* relacionando estas variables

Ejemplo Árbol de Decisión

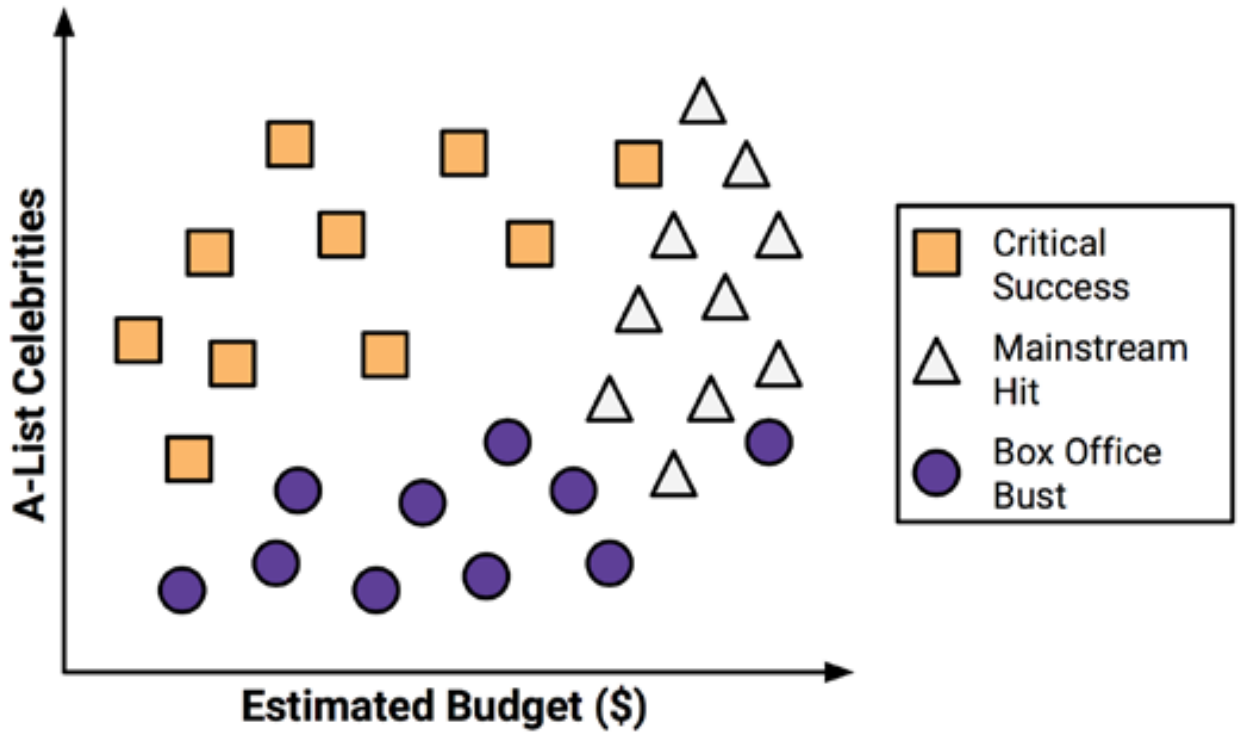

Árboles de Decisión

- El patrón es claro: el número de actores estrella determina si la película será un fracaso de taquilla o no
- Despúes, dependiendo del presupuesto es un éxito para la crítica o un éxito de taquilla
- Para crear el nodo raíz, se dividen las películas entre las que tienen muchas o pocas celebridades
- Luego, entre las que tienen alto número de celebridades, dividimos entre las que gastan mucho y las que gastan poco

Ejemplo Árbol de Decisión

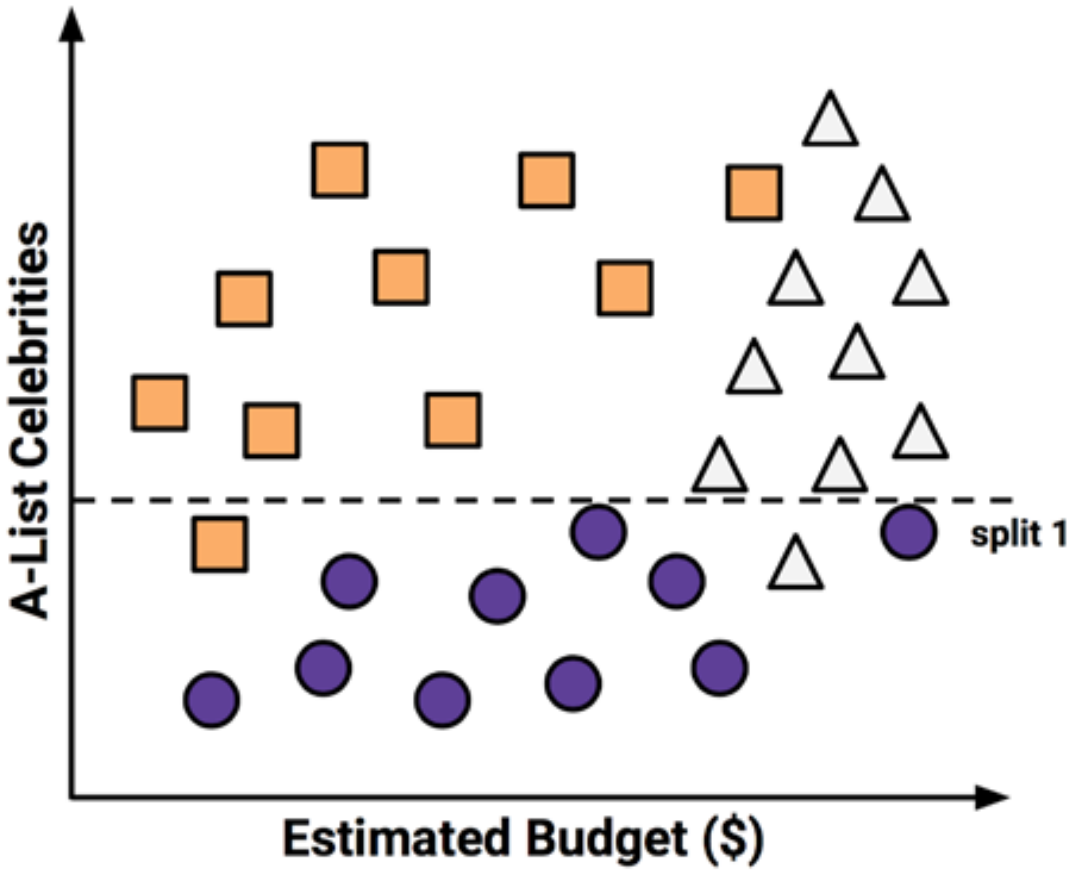

Ejemplo Árbol de Decisión

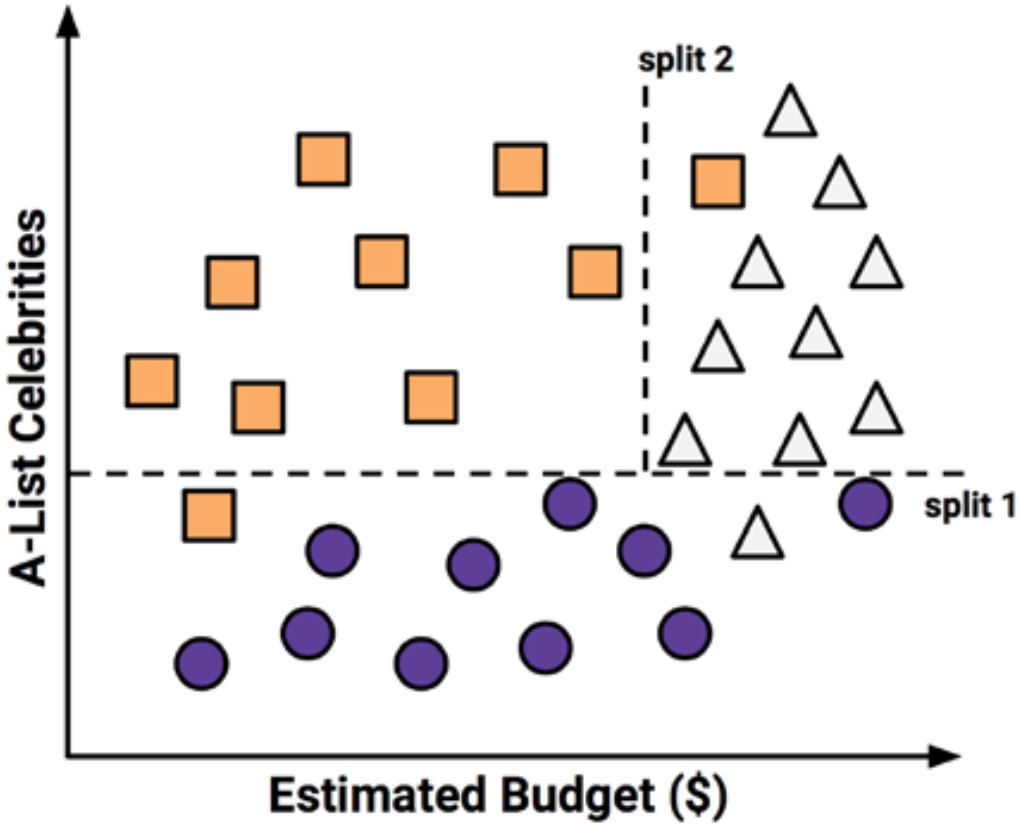

Árboles de Decisión

- Quedamos con tres grupos
- La esquina superior izquierda solo con éxitos para la crítica
- La esquina superior derecha mayoritariamente con éxitos de taquilla
- La sección inferior con fracasos de taquilla
- Podemos predecir: un candidato nuevo, en función del número de celebridades y el presupuesto, cae en uno de los grupos
- Este modelo de decisión lo podemos representar como un árbol

Ejemplo Árbol de Decisión

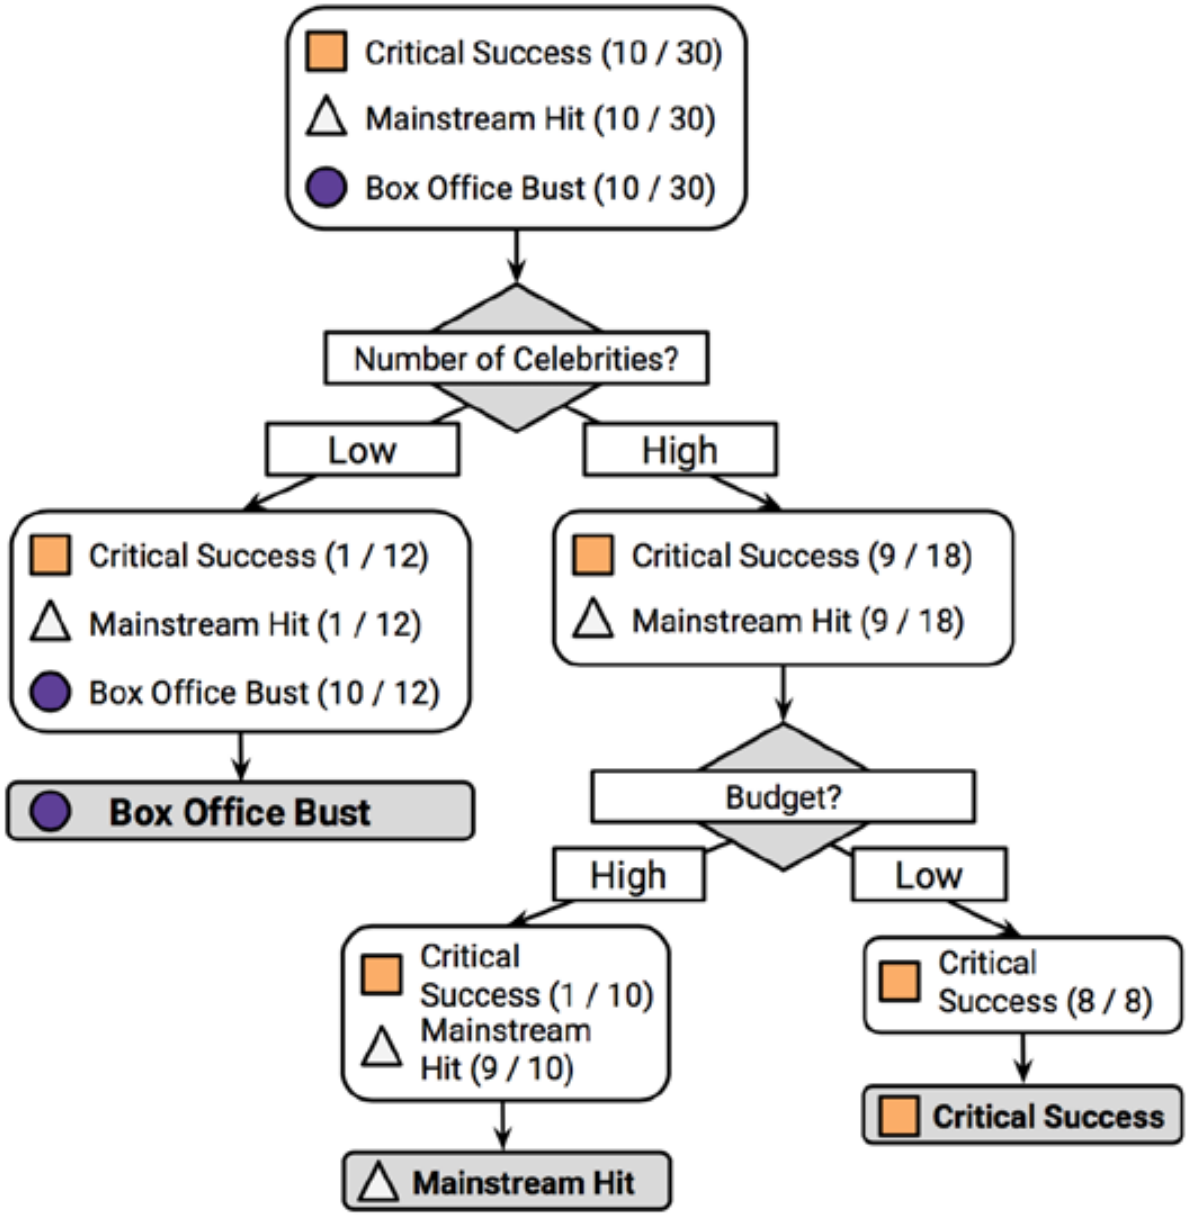

Algoritmo C5.0

- Quedamos con tres grupos
- Hay diversas formas de implementar los árboles de decisión
- Uno de los más usados es el algoritmo C5.0. Es el estándar en la industria
- Es la evolución del algoritmo C4.5, que a su vez es la evolución de ID3, y así sucesivamente
- Es popular porque generalmente tiene buen desempeño, es fácil de entender y de implementar

Algoritmo C5.0

Las principales fortalezas del C5.0 son:

1. Clasificador para todos los propósitos de buen desemepeño en casi todo problema
2. Proceso de aprendizaje altamente automático, capaz de manejar variables numéricas o categóricas o valores ausentes
3. Excluye características irrelevantes
4. Produce un modelo que puede interpretarse sin contexto matemático
5. Más eficiente que otros modelos más complejos

Algoritmo C5.0

Las principales debilidades del C5.0 son:

1. Los árboles suelen tener un sesgo hacia divisiones en características con muchos niveles
2. Es fácil sobreestimar o subestimar el modelo
3. Puede ser difícil modelar algunas relaciones porque se basa en divisiones paralelas a los ejes
4. Pequeños cambios en los datos de entrenamiento pueden llevar a grandes cambios en la lógica de decisión
5. Árboles muy grandes pueden ser difíciles de interpretar y las decisiones pueden ser contraintuitivas

¿Cómo Dividir de la Mejor Forma?

- El primer reto es decidir sobre qué característica empezar a dividir
- En el caso de las películas, dividimos para lograr que cada subconjunto tuviera solo una clase de objeto
- **Pureza**: nivel al cual un subconjunto de ejemplos contiene una única clase
- **Subconjunto Puro**: Aquel que contiene una única clase

Índice de Entropía

- Existen varias formas de medir pureza
- La más utilizada es el índice de entropía:

$$Entropy(S) = \sum_{i=1}^{c} -p_i log_2(p_i)$$

- Donde S es un segmento de datos, c es el número de niveles de clase
- p_i es la proporción de clases en S que caen en el nivel c
- Cuánto mayor sea el índice, más heterogeneidad. Buscamos minimizar le entropía

Ejemplo: Índice de Entropía

- Supongamos que tenemos una partición de los datos S con dos clases ($c = 2$):
- Rojo: $p_1 = 60\%$; Blanco: $p_2 = 40\%$
- El índice de entropía es

$$Entropia(S) = -0.6 * \log_2(0.6) - 0.4 \log_2(0.4) = 0.97$$

- Hay poca homogeneidad. En cambio, si tuviéramos $p_1 = .95$ y $p_2 = .5$, la entropía sería 0.28.
- Mucha más homogeneidad en este caso

Índice de Entropía

Si x es la proporción en el grupo 1, tenemos:

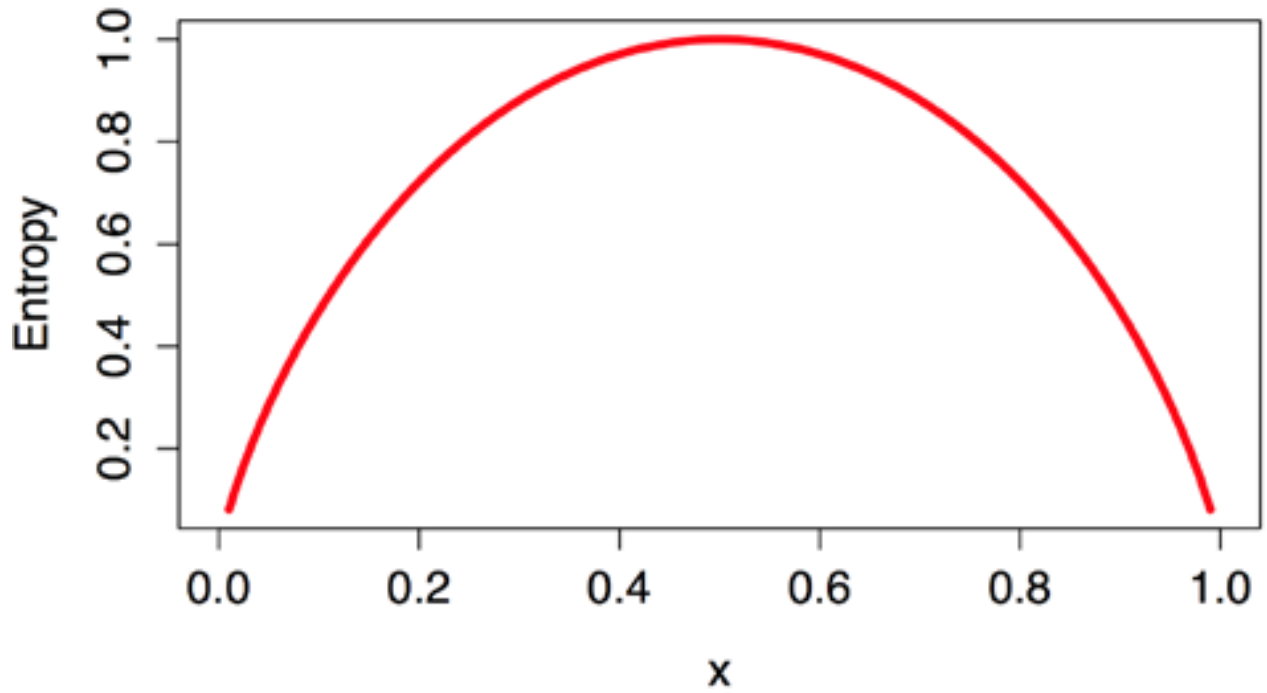

¿Cómo Dividir de la Mejor Forma?

- Pero la pregunta es cuál es la característica óptima para dividir
- Para ello el algortimo calcula el cambio en la homogeneidad que resultaría de dividir cada posible categoría
- Esta medida se llama *ganancia de información*
- Para una característica F la ganancia de información es

$$InfoGain(F) = Entropy(S_1) - Entropy(S_2)$$

- $Entropy(S_1)$ es la entropía del segmento antes de la partición y $Entropy(S_2)$ en las particiones después de la partición

¿Cómo Dividir de la Mejor Forma?

- ¿Cómo se calcula la entropía de las particiones que genera una divisón?

$$Entropy(S) = \sum_{i=1}^{n} w_i Entropy(p_i)$$

- donde w_i es la proporción de ejemplos que caen en la partición i, para las n particiones generadas

- Es decir, se hace una suma ponderada de las entropías de cada grupo

¿Cómo Dividir de la Mejor Forma?

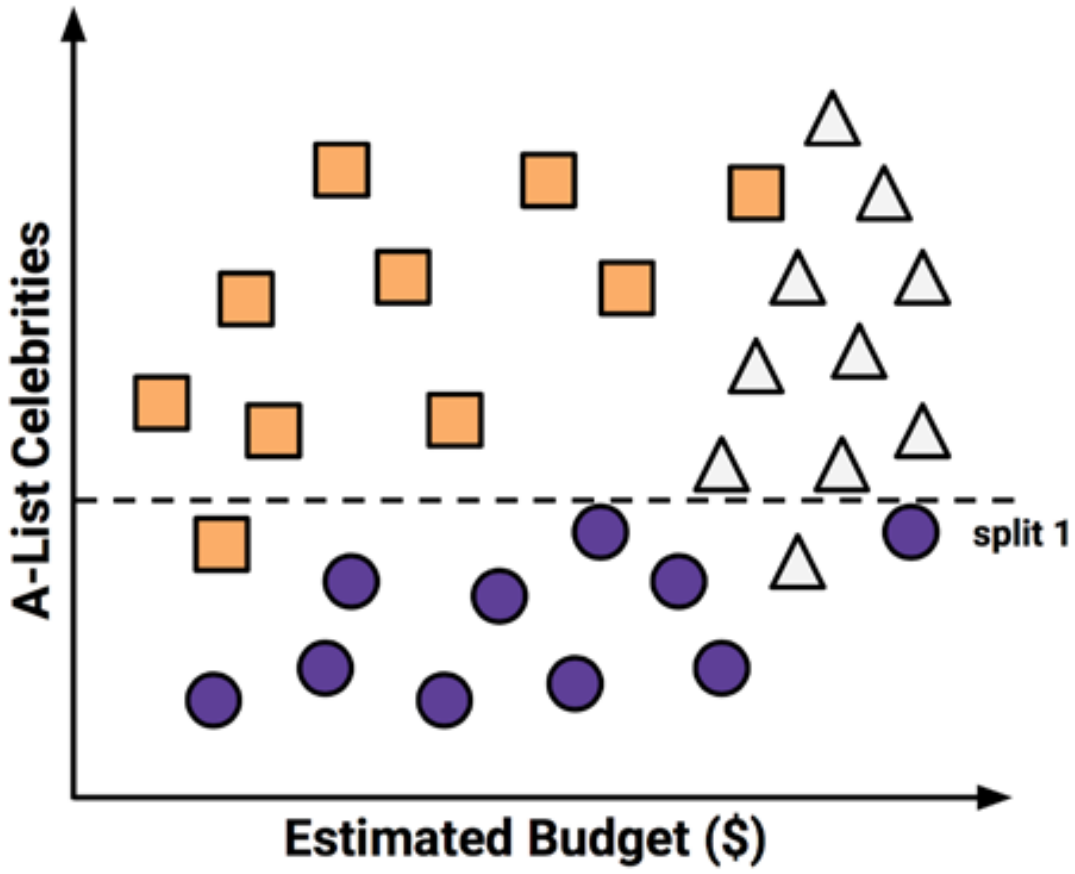

¿Cómo Dividir de la Mejor Forma?

- En el ejemplo la ganancia de información es mayor cuando se divide primero en número de celebridades
- Al hacerlo así nos queda una partición donde prácticamente todos son de la misma clase
- Dividiendo primero por presupuesto quedaríamos con dos grupos bastante heterogéneos
- Si la ganancia de información es cero, la división no sirve de nada pues se tiene la misma entropía
- Cuando la ganancia es igual a la entropía original, es porque la entropía final es 0, y los grupos resultantes son homogéneos

¿Cómo Dividir de la Mejor Forma?

- En el método anterior se asumen características nominales
- ¿Y si son numéricas? Se hace algo parecido
- Se prueban diferentes umbrales de la característica numérica
- Y se escoge la que genere mayor ganancia de información

¿Cuándo Parar?

- Es riesgoso seguir dividiendo indiscriminadamente el árbol
- Esto llevaría a un *overfitting* del modelo. Lo cual hace que las reglas sean inútiles para predecir
- Hay reglas para saber cuándo parar: pueden ser pre-poda o post-poda
- Si ex-ante se establece un número máximo de decisiones o de ejemplos en los nodos de decisión se está ante pre-poda
- Si se deja crecer el árbol para luego cortar lo que no es necesario, se está ante post-poda